KECERDASAN ARTIFISIAL – TKEE262513

LAPORAN *MINI-PROJECT MACHINE LEARNING*
PREDIKSI BEBAN LISTRIK PER JAM SATU HARI KE DEPAN *(DAY-AHEAD LOAD FORECASTING)* DAN SEGMENTASI PROFIL BEBAN HARIAN PADA JARINGAN PJM



DISUSUN OLEH: KELOMPOK 14

1. Alfito Putra Parindra NIM. 24/534768/TK/59290
2. Muhammad Fasha NIM. 24/535041/TK/59325
3. Najamudin Fawwaz Haq NIM. 24/539273/TK/59804
4. Qais Faqih Basyaev NIM. 24/542181/TK/60189
5. Muhammad Zeva Hardi Seswanto NIM. 24/542780/TK/60292

DEPARTEMEN TEKNIK ELEKTRO DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026

DAFTAR ISI

BAB 1. PENDAHULUAN 2
1.1 LATAR BELAKANG 2
1.2 INPUT, OUTPUT, DAN PERANGKAT UJI COBA 3
1.3 TUJUAN PENGGUNAAN AI 3
1.4 BATASAN MASALAH 4
BAB 2. METODE DAN MODEL AI 4
2.1 AI FORMULATION 4
2.2 DATA/KNOWLEDGE PREPARATION 5
BAB 3. HASIL DAN PEMBAHASAN 8
3.1 IMPLEMENTATION 8
3.2 RESULTS 11
3.3 EVALUATION 24
3.4 ENGINEERING INTERPRETATION 26
BAB 4. KESIMPULAN 28
DAFTAR PUSTAKA 29
LAMPIRAN 31
LAMPIRAN 1. DASHBOARD WEBSITE MINI-PROJECT AI 31
LAMPIRAN 2. TAUTAN GITHUB REPOSITORY DAN FOLDER GOOGLE DRIVE DARI NOTEBOOK MODEL AI YANG DIKEMBANGKAN 31
LAMPIRAN 3. GRID HYPERPARAMETER HGB 32
LAMPIRAN 4. HASIL CLUSTERING PADA SEPULUH WILAYAH 32

BAB 1. PENDAHULUAN

1.1 LATAR BELAKANG

Listrik merupakan infrastruktur yang menopang hampir seluruh kegiatan ekonomi dan sosial, dan kebutuhannya di Indonesia terus bertambah. Konsumsi listrik per kapita Indonesia mencapai 1.285 kWh pada Oktober 2023 [1], sedangkan ESDM menyebut rata-rata ASEAN sebesar 3.672 kWh per kapita [2]. Pemerintah menargetkan tambahan kapasitas pembangkit 69,5 GW dalam RUPTL 2025–2034 [3], dan PLN memproyeksikan kebutuhan listrik naik dari 306 TWh menjadi 511 TWh pada 2034 [4]. Pertumbuhan ini harus dikelola oleh operator sistem yang setiap saat menyeimbangkan daya yang dibangkitkan dengan daya yang dikonsumsi.

Sistem Jawa-Bali menunjukkan skala masalahnya. Beban puncak malam sistem ini tercatat 27.070 MW pada 17 Oktober 2018 [5], dan kelebihan pasok (*oversupply*) turun dari 7 GW pada akhir 2022 menjadi 4 GW pada akhir 2023 [6]. Prediksi beban yang terlalu rendah berisiko membuat cadangan daya tidak mencukupi, sedangkan prediksi yang terlalu tinggi membuat pembangkit beroperasi lebih banyak dari kebutuhan. Di sisi lain, 42,6 GW dari 69,5 GW kapasitas baru dalam RUPTL berasal dari energi terbarukan dan 10,3 GW dari penyimpanan energi [3], sehingga perencanaan operasi harian makin menuntut prediksi beban yang akurat. Nilai ekonominya pun nyata: perkiraan kasar menyebut penurunan *error* prediksi beban jangka pendek sebesar 1 poin persentase (MAPE dari 4% menjadi 3%) menghemat sekitar US$300.000 per tahun untuk utilitas dengan beban puncak 1 GW [7].

Prediksi beban jangka pendek dengan *machine learning* sudah diteliti pada sistem Indonesia. Ainuri dkk. memakai *Long Short-Term Memory* (LSTM) pada sistem Jawa-Bali dan memperoleh MAPE 5,67% serta RMSE 1.683,09 MW pada model terbaiknya [8]. Namun, dalam penelusuran kami tidak ditemukan data beban per jam sistem Indonesia yang dapat diunduh secara publik, sehingga metode sulit direproduksi dan dibandingkan secara terbuka. Sebagai gantinya, data beban per jam PJM Interconnection tersedia secara publik [9]–[13]. PJM melayani 65 juta penduduk di 13 negara bagian dan District of Columbia, dengan perkiraan beban puncak musim panas sekitar 149.000 MW dan kapasitas terpasang sekitar 185.000 MW [14]. Skala ini cukup besar untuk menguji metode pada beberapa wilayah dengan karakter beban berbeda.

Berdasarkan uraian tersebut, *mini project* ini membangun model prediksi beban *day-ahead* per jam dengan HistGradientBoosting (HGB) pada data PJM, dan mengelompokkan hari berdasarkan profil beban 24 jam dengan K-Means. Model diuji pada sepuluh wilayah dengan pembagian data kronologis dan dibandingkan dengan *baseline* sederhana, sehingga peningkatan akurasinya dapat diukur secara terbuka. Hasilnya diharapkan menjadi acuan metode yang dapat diterapkan pada data beban sistem Indonesia ketika data tersebut tersedia.

1.2 *INPUT, OUTPUT,* DAN PERANGKAT UJI COBA

Masukan, keluaran, dan perangkat uji coba sistem pada setiap pendekatan AI disajikan dalam Tabel 1 sebagai berikut.

Tabel 1. *Input*, *Output,* Perangkat Uji Coba Sistem

Komponen	Keterangan
Input (*regression*)	Informasi kalender, meliputi jam, hari dalam pekan, bulan, dan hari libur nasional Amerika Serikat, serta riwayat beban yang tersedia hingga pukul 23:00 hari D−1.
Output (*regression*)	Sebanyak 24 nilai prediksi beban dalam MW, masing-masing untuk setiap jam pada hari D.
Input (*clustering*)	Satu profil beban yang terdiri atas 24 nilai per jam untuk setiap hari.
Output (*clustering*)	Label cluster setiap hari dan uraian karakteristik masing-masing cluster.
Bahasa Pemrograman	Python 3.11
Library	pandas 3.0, NumPy 2.4, Matplotlib 3.10, scikit-learn 1.8 [15], holidays 0.106 [16]
Platform	Jupyter Notebook (*pjm_load_forecasting.ipynb*)
Sistem operasi	Linux
Perangkat keras	2 CPU, RAM 7 GB, tanpa GPU
Random seed	42

1.3 TUJUAN PENGGUNAAN AI

Beban listrik dipengaruhi oleh pola harian, mingguan, dan tahunan, serta keberadaan hari libur. Pengaruh berbagai pola tersebut terhadap besarnya beban tidak bersifat linear dan dapat saling berinteraksi. Sebagai contoh, profil beban harian pada musim panas dapat berbeda dari musim dingin, sebagaimana profil hari kerja dapat berbeda dari akhir pekan. Keragaman kombinasi tersebut sulit diwakili secara menyeluruh melalui aturan IF–THEN.

Machine learning memungkinkan hubungan tersebut dipelajari dari data historis dalam jumlah besar. Pada wilayah PJME, tersedia 145.366 baris data mentah yang digunakan sebagai

dasar analisis. Dengan pendekatan ini, pola beban diidentifikasi melalui pembelajaran dari data, sehingga tidak bergantung pada penyusunan aturan secara manual.

1.4 BATASAN MASALAH

Batasan ruang lingkup *mini project* ini ditetapkan sebagai berikut.

1. Informasi yang digunakan model terbatas pada kalender dan riwayat beban. Karena *dataset* tidak menyediakan data cuaca, pengaruh suhu tidak dimodelkan.
2. Prediksi dibuat satu kali setiap hari, yaitu pukul 00:00, untuk mencakup 24 jam pada hari tersebut (*day-ahead*).
3. Analisis dilakukan pada 10 wilayah PJM. Seri NI dan PJM_Load yang juga tersedia dalam paket data tidak disertakan karena masing-masing berakhir pada Januari 2011 dan Januari 2002, sehingga tidak mencakup periode pengujian (*testing*).
4. Data yang dianalisis berasal dari Amerika Serikat. Oleh karena itu, hasil yang diperoleh belum tentu dapat diterapkan secara langsung pada sistem kelistrikan Indonesia.
5. Keluaran model berupa satu nilai prediksi untuk setiap jam, tanpa menyertakan interval ketidakpastian (*prediction interval*).

BAB 2. METODE DAN MODEL AI

2.1 *AI FORMULATION*

Pendekatan kecerdasan artifisial yang digunakan pada proyek adalah *regression* dalam prediksi beban dengan keluaran yang diprediksi berupa nilai numerik kontinu, yaitu beban listrik dalam MW. Sementara itu, digunakan *clustering* (K-Means) sebagai analisis pendukung untuk mengelompokkan profil beban harian tanpa label kelas. Hasil *clustering* dipakai untuk membantu menjelaskan karakteristik data dan tidak dipakai sebagai masukan model *regression*. Formulasi AI yang digunakan pada proyek ditunjukkan pada Tabel 2 sebagai berikut.

Tabel 2. Formulasi AI yang Digunakan

Tujuan	**Pendekatan**	**Masukan/*Input***	**Keluaran/*Output* dan Evaluasi**
Prediksi beban *day-ahead*	*Regression*: HistGradientBoosting (HGB) dengan pembanding: Random Forest, Ridge, dan empat *baseline.*	Kalender dan riwayat beban sampai 23:00 hari D-1 (21 *feature*)	Beban (MW) tiap jam pada hari D; MAE, RMSE, R^2, *relative error*

Tujuan	Pendekatan	Masukan/*Input*	Keluaran/*Output* dan Evaluasi
Segmentasi profil beban harian	*Clustering*: K-Means pada profil dalam MW tanpa standardisasi, hasil *tuning preprocessing*, dan perbandingan 6 algoritma; jumlah *cluster* (k) dipilih dengan *Silhouette Score*	Profil 24 jam per hari dalam MW	Label *cluster*; *Silhouette Score,* Davies-Bouldin Index, stabilitas, R^2 rekonstruksi

Pendekatan utama yang dipilih adalah *regression*, dengan HGB sebagai model utama karena data berbentuk tabel dengan banyak *feature* campuran dan jumlah data yang cukup besar, serta mampu menangkap interaksi antar-*feature* tanpa rekayasa manual. Input model berupa kalender dan riwayat beban sampai pukul 23:00 hari D-1, sedangkan *output* berupa beban listrik tiap jam pada hari D. HGB dibandingkan dengan Random Forest dan Ridge Regression untuk melihat apakah peningkatan akurasi berasal dari algoritma atau dari *feature* yang digunakan. Empat *baseline* tanpa proses *learning* juga dipakai sebagai pembanding minimum, sehingga ketika model tidak lebih baik dari *baseline* tersebut, penggunaan *machine learning* tidak memberikan manfaat. Pada proyek ini, satu model dipakai untuk seluruh jam dalam sehari, dengan jam sebagai salah satu *feature*.

Pendekatan pendukung adalah *clustering* dengan *unsupervised learning*, karena data beban tidak memiliki label jenis hari sehingga mampu untuk meringkas pola beban harian dalam pengelompokan sesuai dengan kemiripan bentuk profil. *Input* berupa profil beban 24 jam per hari dan *output* berupa label *cluster* untuk tiap hari dengan algoritma yang dipakai adalah K-Means. K-Means mengelompokkan setiap hari ke pusat *cluster* (*centroid*) terdekat dengan *centroid* berupa rata-rata profil beban dalam MW sehingga setiap *cluster* mudah dibaca dan dikaitkan dengan musim atau akhir pekan. Pada proyek ini, jumlah *cluster* (k) ditentukan dari Silhouette Score.

2.2 *DATA/KNOWLEDGE PREPARATION*

2.2.1 Sumber dan Karakteristik *Dataset*

Data yang digunakan pada proyek ini adalah data riil/nyata dari *open-public sources* sebagai berikut.

1. Repositori GitHub: panambY (Hourly_Energy_Consumption)
2. Repositori Kaggle: robikscube (Hourly Energy Consumption)
3. Repositori Kaggle: ashishkumarrana (PJM Hourly Energy Consumption)
4. Repositori Github: navyasancheti (PJME-Hourly-Energy-Consumption)
5. IEEE Dataport: PJM Hourly Energy Consumption

Setiap berkas terdiri atas dua kolom, yaitu *Datetime* (*timestamp* per jam) dan beban listrik dalam MW. Pada PJME terdapat 145.366 baris mentah, yang mencakup 4 timestamp ganda dan 30 jam

yang hilang (*missing value*), seluruhnya berupa celah sepanjang 1 jam. Data PJME yang dipakai mencakup 2002-01-02 sampai 2018-08-02 dengan 145.368 jam (6.057 hari). Beban rata-rata 32.079 MW dengan simpangan baku 6.465 MW, nilai minimum 14.544 MW, dan nilai maksimum 62.009 MW.

2.2.2 Pra-pemrosesan Data

Pra-pemrosesan data atau *preprocessing* dilakukan dengan aturan yang sama pada semua wilayah. Pertama, *duplicate timestamp* yang muncul akibat pergantian *daylight saving time* diambil yang pertama. Kedua, data diubah menjadi *hourly time series* tanpa *gap*, sehingga jam yang hilang menjadi *missing value*. Ketiga, *outlier*, yaitu nilai nol, nilai negatif, atau nilai di bawah 35% dari *local median* pada *hour-of-week* yang sama (*window* 9 minggu), diubah menjadi *missing value*. Keempat, *gap* sampai 6 jam diisi dengan *linear interpolation*. Kelima, hanya *complete day* (24 jam penuh) yang dipakai. Nilai tinggi tidak dibuang karena *peak load* yang ekstrem merupakan kondisi nyata yang justru perlu diprediksi. Nilai di antara 35% dan 50% dari *local median* dicatat sebagai *suspicious value*, tetapi tetap dipertahankan karena tidak dapat dibuktikan salah. Dengan demikian, diperoleh hasil pra-pemrosesan data pada setiap wilayah yang ditunjukkan pada Tabel 3 sebagai berikut.

Tabel 3. Hasil Pra-pemrosesan Data Setiap Wilayah

Wilayah	**Periode**	**Hari**	***Missing hour***	***Duplicate timestamp***	***Removed value***	***Suspicious value***
PJME	2002-01 s.d. 2018-08	6.057	30	4	0	0
AEP	2004-10 s.d. 2018-08	5.053	27	4	0	0
COMED	2011-01 s.d. 2018-08	2.770	11	4	0	0
DOM	2005-05 s.d. 2018-08	4.841	23	4	1	0
FE	2011-06 s.d. 2018-08	2.619	10	4	1	0
PJMW	2002-04 s.d. 2018-08	5.967	30	4	1	0
DEOK	2012-01 s.d. 2018-08	2.405	9	4	0	30
DAYTON	2004-10 s.d. 2018-08	5.053	25	4	0	1

Wilayah	Periode	Hari	*Missing hour*	*Duplicate timestamp*	*Removed value*	*Suspicious value*
DUQ	2005-01 s.d. 2018-08	4.961	24	4	0	0
EKPC	2013-06 s.d. 2018-08	1.888	6	4	0	10

Berdasarkan Tabel 3, setiap wilayah hanya memiliki *gap* data sepanjang 1 jam (*gap* terpanjang 1 jam) dan 4 *duplicate timestamp*. Jumlah *missing hour* tergolong sangat kecil dibanding jumlah data sehingga *interpolation* tidak mengubah pola beban secara berarti. *Outlier* yang dibuang hanya 3 titik, yaitu DOM pada 2009-12-12 00:00 (1.253 MW, 14% dari *local median*); FE pada 2011-06-01 01:00 (0 MW, 0% dari *local median*); PJMW pada 2003-05-29 00:00 (487 MW, 10% dari *local median*). *Suspicious value* yang dipertahankan terdapat pada DAYTON (1 jam), DEOK (30 jam), EKPC (10 jam). Pada DEOK, 29 dari 30 jam tersebut berada pada 22–25 April 2018 (21 jam pada 22 April) sehingga masuk ke periode *testing* dan dapat sedikit menaikkan *error* DEOK. Pada EKPC, 10 jam tersebut berada pada tahun 2013 (periode *training*).

2.2.3 Pembentukan *Feature* dan Target

Target yang diprediksi adalah beban pada jam *t* (MW). Prediksi dibuat pukul 00:00 hari *D* untuk 24 jam hari *D*, sehingga hanya data sampai pukul 23:00 hari *D-1* yang boleh dipakai. Oleh karena itu, setiap *feature* berbasis beban memakai *lag* minimal 24 jam atau nilai *snapshot* pada pukul 23:00 hari *D-1*. Aturan ini mencegah *data leakage*, yaitu masuknya informasi dari waktu yang sedang diprediksi ke dalam *feature*. Seluruh 21 *feature* dirinci pada Tabel 4 berikut.

Tabel 4. Daftar *Feature* yang Digunakan

Kelompok	Nama *Feature*	Keterangan Penjelasan
Kalender (6)	hour, dow, month	Jam (0–23), hari dalam pekan (0 = Senin), dan bulan
	is_hol, hol_prev, hol_next	Penanda hari libur nasional AS pada hari D, hari sebelumnya, dan hari sesudahnya (library *holidays*)
Lag (6)	lag24, lag48, lag168, lag336	Beban pada jam yang sama 1, 2, 7, dan 14 hari sebelumnya
	wk_mean	Rata-rata beban pada jam yang sama selama 7 hari terakhir
	dmean_prev	Rata-rata beban 24 jam yang berakhir pada jam t-24
Snapshot D-1 (9)	last_obs, last_obs_m3, last_obs_m6	Beban pukul 23:00, 20:00, dan 17:00 pada hari D-1

Kelompok	Nama *Feature*	Keterangan Penjelasan
	d1_mean, d1_max, d1_min	Rata-rata, maksimum, dan minimum beban 24 jam yang berakhir pukul 23:00 hari D-1
	w1_mean, d1_trend	Rata-rata beban 7 hari yang berakhir pukul 23:00 hari D-1, dan selisih d1_mean dengan rata-rata 24 jam sebelumnya
	lag72	Beban pada jam yang sama 3 hari sebelumnya

2.2.4 Pembagian Data dan Uji Data *Leakage*

Data dibagi secara kronologis (chronological split) tanpa shuffling. Data training mencakup 2002-01-16 sampai 2014-12-31 (113.592 jam), sedangkan data testing mencakup 2015-01-01 sampai 2018-08-02 (31.440 jam, 21,7% dari seluruh data). Pembagian kronologis dipilih karena pada kondisi nyata model selalu memprediksi masa depan dari data masa lalu. Hyperparameter tuning hanya dilakukan di dalam data training, dan scaling serta encoding hanya di-fit pada data training. Untuk analisis sepuluh wilayah, periode testing disamakan, yaitu 2016-01-01 sampai 2018-08-02, agar hasil antarwilayah dapat dibandingkan.

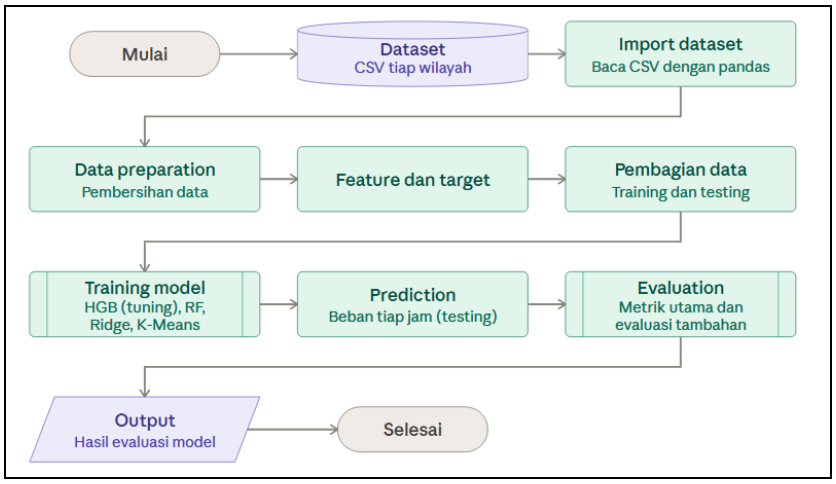
Data leakage diuji dengan perturbation test. Seluruh nilai beban pada satu hari D diganti dengan angka acak, kemudian semua 21 feature dihitung ulang. Jika ada feature pada jam-jam hari D yang ikut berubah, berarti feature tersebut memuat informasi dari hari yang sedang diprediksi. Pada 25 hari acak, tidak ada satu pun feature yang berubah. Hasil yang sama diperoleh pada 9 wilayah lain (10 hari acak per wilayah). Dengan demikian, rancangan feature memenuhi aturan bahwa hanya data sampai pukul 23:00 hari D-1 yang digunakan.

BAB 3. HASIL DAN PEMBAHASAN

3.1 *IMPLEMENTATION*

3.1.1 Alur Implementasi

Alur sistem proyek dilakukan berdasarkan *workflow* yang ditunjukkan diagram alir pada Gambar 1 sebagai berikut.



Gambar 1. Diagram Alir Implementasi Model AI

3.1.2 *Regression Day-Ahead*

Model utama adalah HistGradientBoostingRegressor dari scikit-learn. Model ini membangun banyak *decision tree* secara berurutan, dengan setiap *tree* memperbaiki sisa *error* dari *tree* sebelumnya, dan memakai histogram untuk mempercepat pencarian titik pemisah. Model ini pun dilakukan *tuning* dengan *hyperparameter tuning* menggunakan GridSearchCV pada 16 kombinasi parameter, *cross-validation* berbasis TimeSeriesSplit dengan 4 fold, dan skor MAE. Seluruh proses ini hanya memakai data *training*. Parameter terbaik adalah learning_rate 0,06, max_iter 800, max_leaf_nodes 31, dan min_samples_leaf 50.

Hasil yang diperoleh dibandingkan dengan pembanding, yaitu Random Forest (300 *tree*, min_samples_leaf 5, max_features 0,5) dan Ridge Regression (alpha 10) dengan *one-hot encoding* untuk *feature* kalender. Empat *baseline* tanpa proses *learning* juga dihitung: (1) persistensi harian (lag24), yaitu beban pada jam yang sama kemarin; (2) persistensi mingguan (lag168), yaitu beban pada jam yang sama minggu lalu; (3) rata-rata lag24, lag48, dan lag168; serta (4) rata-rata beban pada jam yang sama selama 7 hari terakhir.

3.1.3 *Clustering* Profil Beban Harian

Pada proyek ini, setiap hari direpresentasikan oleh 24 nilai beban per jam (6.057 hari lengkap pada PJME). Analisis tersebut bersifat deskriptif karena memakai data hari itu sendiri sehingga tidak ada isu *data leakage*. Sementara itu, konfigurasi awal memakai data yang distandarkan per jam dan K-Means dengan k dipilih dari Silhouette Score. Konfigurasi tersebut kemudian dilakukan *tuning* dan dibandingkan dengan algoritma lain. Rancangan konfigurasi tersebut dirinci sebagai berikut.

1. *Preprocessing* (10 varian): standardisasi per jam (konfigurasi awal), MW asli tanpa standardisasi, *robust scaling*, *min-max*, log lalu standardisasi, bentuk saja (z-score per hari), bentuk saja (rasio ke rata-rata harian), bentuk + level (bentuk ditambah rata-rata harian terstandar), PCA 95% variansi, dan PCA 3 komponen.

2. Algoritma (6 jenis): K-Means, *Gaussian Mixture Model* (kovarians *full* dan *diagonal*), *Agglomerative clustering* (*linkage* Ward dan *average*), serta *spectral clustering*. Jumlah *cluster* k diuji dari 2 sampai 6, sehingga totalnya 265 konfigurasi pada PJME.
3. Ukuran: Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz, stabilitas, dan R^2 rekonstruksi. Stabilitas adalah rata-rata *Adjusted Rand Index* (ARI) antara dua hasil *clustering* pada dua *subsample* acak 70% data, dibandingkan pada hari yang sama (5 ulangan). R^2 rekonstruksi menunjukkan seberapa besar variasi profil MW yang dijelaskan oleh rata-rata *cluster*.

Silhouette Score dihitung di ruang fitur milik tiap konfigurasi, sehingga angkanya tidak bisa dibandingkan langsung antar-*preprocessing* karena jarak diukur di ruang yang berbeda. Untuk perbandingan, setiap hasil *clustering* dinilai ulang di dua ruang pembanding netral, yaitu S1 (data distandarkan per jam) dan S2 (bentuk profil saja, z-score per hari), dan *score* didefinisikan sebagai rata-rata Silhouette di S1 dan S2. Sebelum hasil dilihat, ditetapkan aturan seleksi: pilih konfigurasi dengan *score* tertinggi yang memiliki stabilitas minimal 0,8 dan *cluster* terkecil minimal 5% dari seluruh hari. Perbedaan antar-kandidat teratas diuji dengan 10 kali *subsample* 70% berpasangan (kandidat dan K-Means standar dinilai pada *subsample* yang sama). Pengujian diulang pada 9 wilayah lain dengan 5 konfigurasi terpilih.

3.1.4 Evaluasi Tambahan

Empat analisis tambahan dilakukan di luar evaluasi pada satu periode *testing*. *Ablation study* membandingkan tiga kelompok *feature* (kalender saja; kalender dan *lag*; semua *feature*) untuk melihat kontribusi tiap kelompok. Evaluasi *rolling-origin* mengulang proses *training* dan *testing* pada 8 periode berurutan (masing-masing sekitar 6 bulan) untuk melihat konsistensi hasil terhadap waktu. Analisis *error* melihat sebaran *error* menurut jam, bulan, dan jenis hari. *Permutation importance* mengukur seberapa besar MAE naik ketika nilai suatu *feature* diacak.

3.1.5 *Pipeline* Multi-Wilayah

Setiap wilayah dilatih dengan model tersendiri menggunakan *pipeline* yang sama, yaitu 21 *feature* yang sama, empat *baseline*, *tuning* HGB pada grid 8 kombinasi dengan TimeSeriesSplit 4 *fold*, pembanding Ridge, evaluasi *rolling-origin*, *clustering* K-Means, dan *perturbation test*. Terdapat beberapa perbedaan dengan analisis utama PJME.

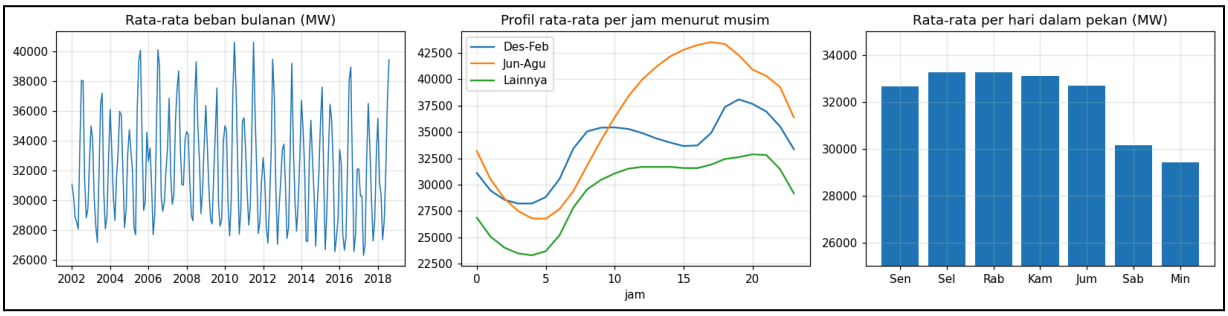
1. Periode *testing* disamakan pada 2016-01-01 sampai 2018-08-02 untuk semua wilayah. Wilayah dengan data pendek seperti EKPC (mulai pertengahan 2013) tetap memiliki data *training* sekitar 2,6 tahun. PJME diulang pada protokol ini hanya untuk tabel perbandingan, sedangkan hasil utama PJME (*testing* mulai 2015) tidak diubah. Karena itu, angka PJME pada tabel perbandingan sedikit berbeda dari hasil utama.
2. Set *feature* dan rentang *hyperparameter* tidak disetel ulang untuk tiap wilayah karena keduanya dirancang pada PJME. Untuk wilayah lain, hanya nilai *hyperparameter* yang dicari ulang pada data *training*.

3. Untuk menghemat waktu komputasi, Random Forest tidak dijalankan per wilayah, *ablation study* hanya memakai tiga set pada satu pembagian data *holdout*, *perturbation test* memakai 10 hari acak, dan *permutation importance* dihitung pada 4.000 jam.

3.2 *RESULTS*

3.2.1 Eksplorasi Data

Model AI menghasilkan *plot* grafik rata-rata beban bulanan, profil rata-rata per jam menurut musim, dan rata-rata beban menurut hari dalam pekan pada PJME. Setiap grafik yang dihasilkan ditunjukkan pada Gambar 2 sebagai berikut.



(a) (b) (c)

Gambar 2. (a) Rata-rata Beban Bulanan, (b) Profil Rata-rata Per Jam Menurut Musim, dan (c) Rata-rata Beban Menurut Hari dalam Pekan pada PJME

Pada Gambar 2a, rata-rata beban bulanan naik dan turun secara periodik dengan dua puncak dalam setahun, yaitu pada musim panas dan musim dingin, dalam rentang sekitar 26.300 MW (April 2017) sampai 40.600 MW (Juli 2011). Tinggi puncak berbeda dari tahun ke tahun sehingga bulan saja tidak cukup untuk menentukan beban. Pada Gambar 2b, profil musim panas (Juni–Agustus) mencapai puncak sekitar 43.500 MW pada pukul 17:00, sedangkan profil musim dingin (Desember–Februari) memiliki dua puncak, yaitu pada pagi hari dan malam hari (puncak tertinggi sekitar 38.100 MW pada pukul 19:00). Bentuk ini sesuai dengan dugaan bahwa beban pendingin ruangan mendominasi pada sore hari di musim panas, sedangkan beban pemanas dan penerangan menghasilkan dua puncak pada musim dingin. Dugaan ini belum diuji karena *dataset* tidak memuat data suhu.

Sementara itu, pada Gambar 2c, rata-rata beban hari Sabtu (30.163 MW) dan Minggu (29.406 MW) lebih rendah sekitar 8,6% dan 10,9% dibanding rata-rata Senin sampai Jumat (32.996 MW). Hal ini menunjukkan bahwa aktivitas industri dan komersial yang lebih rendah pada akhir pekan terlihat langsung pada kurva beban. Berdasarkan ketiga pola tersebut, jam, hari dalam pekan, bulan, dan hari libur dipilih sebagai *feature* kalender.

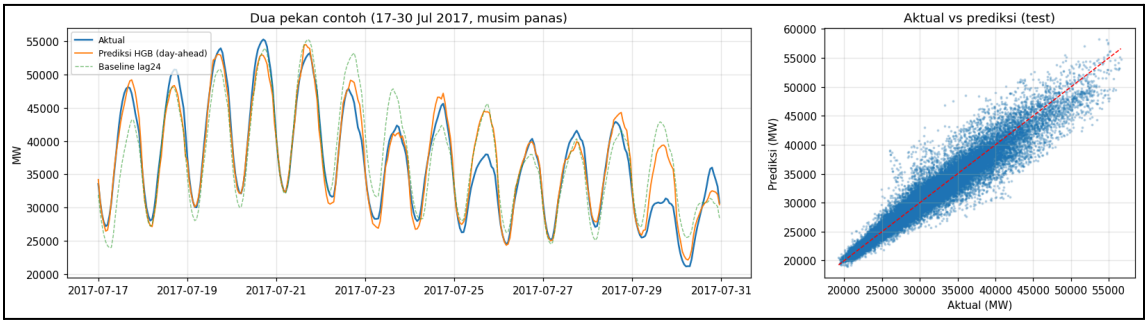
3.2.2 Hasil *Regression*

Model AI *regression* pada proyek ini menghasilkan data perbandingan model dan *baseline* data *testing* PJME yang ditunjukkan Tabel 5 sebagai berikut.

Tabel 5. Perbandingan Model dan *Baseline* pada Data *Testing* PJME

Model	MAE (MW)	RMSE (MW)	R^2	*Relative error*
Baseline: Persistensi harian (lag24)	2.209	3.025	0,780	7,05%
Baseline: Persistensi mingguan (lag168)	3.400	4.645	0,481	10,86%
Baseline: Rata-rata lag24/48/168	2.372	3.146	0,762	7,57%
Baseline: Rata-rata jam sama 7 hari	2.710	3.613	0,686	8,65%
HistGradientBoosting (HGB)	1.275	1.869	0,916	4,07%
Random Forest	1.371	1.968	0,907	4,38%
Ridge (*one-hot* kalender)	1.405	1.942	0,909	4,48%

Berdasarkan Tabel 5, *baseline* terbaik adalah persistensi harian (lag24) dengan MAE 2.209 MW dan R^2 0,780. Persistensi mingguan (lag168) jauh lebih buruk (MAE 3.400 MW), yang menunjukkan bahwa kondisi satu hari sebelumnya lebih informatif daripada kondisi satu minggu sebelumnya untuk prediksi *day-ahead*. HGB mencapai MAE 1.275 MW, RMSE 1.869 MW, dan R^2 0,916, sehingga MAE turun 42,3% dan RMSE turun 38,2% dibanding *baseline* lag24. *Relative error* 4,07% berarti rata-rata penyimpangan prediksi sekitar 4,1% dari beban rata-rata pada periode *testing* (31.323 MW). Random Forest (R^2 0,907) dan Ridge (R^2 0,909) berada sangat dekat dengan HGB. Selisih antara algoritma ini jauh lebih kecil daripada selisih terhadap *baseline* sehingga peningkatan akurasi terutama berasal dari *feature* yang digunakan dan bukan dari kompleksitas algoritma. Hasil ini direpresentasikan pada plot grafik yang ditunjukkan pada Gambar 3 sebagai berikut.



(a) (b)

Gambar 3. Prediksi HGB Dibanding Beban Aktual dan *Baseline* lag24 pada 17–30 Juli 2017 (a) serta Sebaran Nilai Aktual terhadap Prediksi pada Seluruh Data *Testing* (b)

Pada Gambar 3a, prediksi HGB mengikuti siklus harian beban aktual dengan baik, termasuk penurunan beban pada akhir pekan (22–23 Juli dan 29–30 Juli 2017). *Baseline* lag24 tampak tertinggal satu hari: pada peralihan dari hari kerja ke akhir pekan, *baseline* masih membawa level beban hari kerja sehingga prediksinya jauh di atas beban aktual. HGB dapat menyesuaikan karena memperoleh informasi hari dalam pekan. Meskipun demikian, HGB belum sempurna. Pada beberapa hari, misalnya sekitar 25 Juli dan malam hari 30 Juli, selisih antara prediksi dan beban aktual masih terlihat jelas.

Sementara itu, pada Gambar 3b, titik-titik berkumpul di sepanjang garis diagonal, yang menunjukkan bahwa prediksi berkorelasi kuat dengan nilai aktual. Sebaran titik semakin lebar pada beban di atas sekitar 45.000 MW, yaitu kondisi beban puncak. Dari sisi operasi sistem, kondisi ini penting karena beban puncak merupakan saat cadangan daya paling dibutuhkan, tetapi pada saat itu pula ketidakpastian prediksi paling besar.

3.2.3 *Ablation Study*

Pada proyek ini dilakukan *ablation study* pada *regression* untuk meninjau pengaruh kelompok *feature* terhadap akurasi. Hasil *ablation study* pada proyek ini ditunjukkan pada Tabel 6 sebagai berikut.

Tabel 6. Pengaruh Kelompok *Feature* terhadap Akurasi

Set *feature*	**Jumlah**	***Relative error* CV pada *training***	**MAE *testing* (MW)**	**R^2 *testing***	***Relative error testing***
A. kalender saja	6	7,73%	2.995	0,659	9,56%
B. kalender + *lag* ≥ 24 jam	12	4,89%	1.743	0,863	5,57%
C. B + *snapshot* D-1	21	3,59%	1.275	0,916	4,07%

Berdasarkan Tabel 6, penggunaan *feature* kalender saja (set A) menghasilkan MAE 2.995 MW dan R^2 0,659, yang lebih buruk daripada *baseline* lag24 (MAE 2.209 MW). Artinya, informasi kalender saja tidak cukup untuk memprediksi beban. Penambahan *lag* (set B) menurunkan MAE menjadi 1.743 MW, dan penambahan *snapshot* D-1 (set C) menurunkannya lagi menjadi 1.275 MW, atau 26,9% lebih rendah dibanding set B. Urutan yang sama muncul pada *cross-validation* di dalam data *training* (7,73%, 4,89%, dan 3,59%), sehingga peningkatan ini tidak hanya terjadi pada satu periode *testing*. Dari sudut pandang sistem tenaga, hasil ini menunjukkan bahwa kondisi beban paling akhir sebelum prediksi dibuat, yaitu pukul 23:00 hari D-1, memberikan informasi tambahan yang besar.

3.2.4 Evaluasi *Rolling-Origin*

Evaluasi *rolling-origin* dilakukan pada model *regression* dengan hasil yang disajikan pada Tabel 7 sebagai berikut.

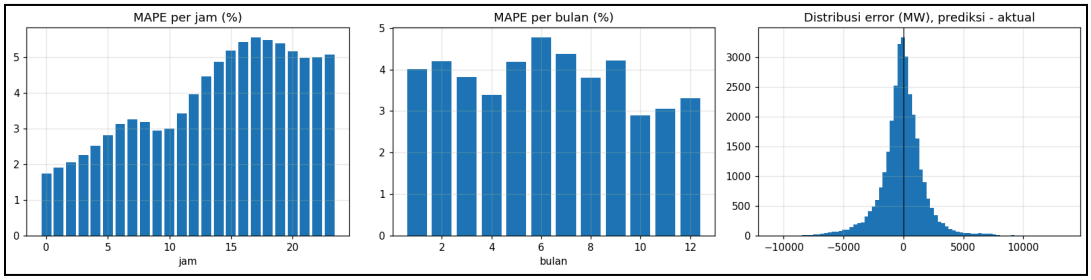
Tabel 7. Hasil *Rolling-Origin* untuk 8 *Fold* (Masing-masing Sekitar 6 Bulan).

Fold	Periode *testing*	*Relative error* HGB	*Relative error* lag24	R^2 HGB
1	2014-08-04 s.d. 2015-02-02	3,65%	6,57%	0,914
2	2015-02-02 s.d. 2015-08-03	4,22%	7,62%	0,912
3	2015-08-04 s.d. 2016-02-02	3,42%	6,40%	0,941
4	2016-02-02 s.d. 2016-08-02	3,90%	6,65%	0,929
5	2016-08-03 s.d. 2017-02-01	3,71%	6,49%	0,931
6	2017-02-01 s.d. 2017-08-02	4,33%	7,50%	0,909
7	2017-08-03 s.d. 2018-02-01	4,03%	6,80%	0,906
8	2018-02-01 s.d. 2018-08-02	4,76%	7,99%	0,876

Pada Tabel 7, HGB lebih baik daripada *baseline* lag24 pada 8 dari 8 *fold*. *Relative error* HGB berkisar antara 3,42% dan 4,76% dengan rata-rata 4,00% (simpangan baku 0,43), sedangkan *baseline* lag24 rata-rata 7,00%. R^2 rata-rata HGB adalah 0,915. Hasil ini menunjukkan bahwa keunggulan HGB konsisten sepanjang waktu dan tidak hanya berlaku pada satu periode *testing*. Rata-rata *rolling-origin* (4,00%) juga dekat dengan hasil pada *testing* utama (4,07%). *Fold* terakhir (Februari–Agustus 2018) memiliki *error* tertinggi (4,76%) dan R^2 terendah (0,876). Namun, *baseline* lag24 juga paling buruk pada *fold* ini (7,99%), sehingga yang sulit adalah periodenya, bukan modelnya. Rasio *error* HGB terhadap *baseline* pada *fold* ini (0,60) memang sedikit lebih tinggi daripada pada fold lain (0,54–0,59), jadi keunggulan HGB sedikit menyempit tetapi tetap ada. Pola serupa tampak pada semua *fold* genap (Februari–Agustus) dengan rata-rata *relative error* HGB 4,30% dibanding 3,70% pada *fold* ganjil (Agustus–Februari), dan *baseline* lag24 mengikuti pola yang sama (7,44% dibanding 6,57%). Penyebab pastinya tidak dilakukan riset lebih lanjut, tetapi pola ini menunjukkan bahwa kenaikan *error* pada fold 2018 merupakan variasi musiman yang juga muncul pada fold-fold sebelumnya, bukan penurunan kualitas model.

3.2.5 Analisis *Error* dan *Feature Importance*

Analisis *error* dan *feature importance* dilakukan berdasarkan MAPE pada jam dalam sehari, menurut bulan, dan distribusi *error* prediksi, yang disajikan pada Gambar 4 berikut.



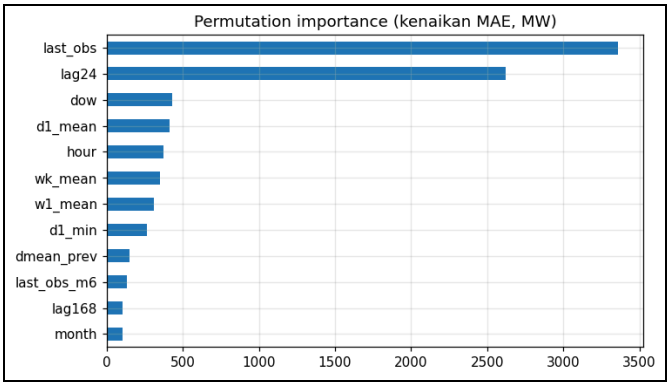
(a) (b) (c)

Gambar 4. (a) MAPE Menurut Jam dalam Sehari, (b) MAPE Menurut Bulan, dan (c) Distribusi *Error* Prediksi, yaitu Prediksi Dikurangi Aktual

Pada Gambar 4a, MAPE naik dari 1,75% pada pukul 00:00 menjadi 5,56% pada pukul 17:00, dan bertahan di sekitar 5,1% pada malam hari. Jam-jam awal memiliki *error* kecil karena dekat dengan *snapshot* pukul 23:00, sedangkan jam-jam berikutnya berjarak semakin jauh dari data terakhir yang diketahui, sampai 24 jam. Selain itu, sore hari merupakan saat beban puncak yang secara fisik lebih bervariasi. Pada Gambar 4b, MAPE tertinggi terjadi pada Juni (4,77%) dan terendah pada Oktober (2,90%). Bulan-bulan musim panas cenderung memiliki *error* lebih besar daripada Oktober sampai Desember. Hal ini konsisten dengan dugaan bahwa beban pendingin yang bergantung pada suhu sulit diprediksi tanpa data cuaca. Sementara itu, MAPE menurut jenis hari menunjukkan bahwa hari kerja memiliki *error* terkecil (3,68%), sedangkan akhir pekan (4,30%) dan hari libur nasional (4,31%) lebih besar. Dari 10 hari dengan MAPE harian terburuk, 8 jatuh pada akhir pekan, dengan yang terburuk pada 2017-05-20 (MAPE 26,4%). Hari-hari tersebut berbeda dari pola hari kerja yang mendominasi data sehingga lebih sulit diprediksi.

Pada Gambar 4c, distribusi *error* berpusat di sekitar nol dan hampir simetris, dengan bias rata-rata -92 MW (sekitar 0,3% dari beban rata-rata), artinya model cenderung sedikit lebih rendah dari beban aktual. Pada 90% jam, *error* absolut tidak melebihi sekitar 2.900 MW, dan pada 99% jam tidak melebihi sekitar 6.681 MW, sedangkan *error* terbesar mencapai 13.556 MW. Ekor distribusi yang panjang menunjukkan bahwa *error* besar jarang terjadi, tetapi tetap mungkin terjadi.

Permutation importance dari HGB pun dievaluasi dalam Gambar 5 berikut.



Gambar 5. *Permutation Importance* HGB, yaitu Kenaikan MAE (MW) Ketika Nilai Suatu *Feature* Diacak

Pada Gambar 5, dua *feature* teratas adalah last_obs (MAE naik 3.359 MW saat diacak) dan lag24 (2.622 MW). Keduanya masing-masing adalah beban pukul 23:00 hari D-1 dan beban pada jam yang sama kemarin. Pengaruh kedua *feature* tersebut jauh lebih besar daripada dow (429 MW), d1_mean (411 MW), dan hour (371 MW). Hal ini sesuai dengan hasil *ablation study*: kondisi beban terbaru adalah informasi paling berharga, sedangkan kalender berperan sebagai koreksi, misalnya untuk membedakan hari kerja dan akhir pekan. Nilai *permutation importance* perlu dibaca dengan hati-hati karena *feature* yang saling berkorelasi, seperti lag24 dan wk_mean, dapat saling menggantikan sehingga pengaruh masing-masing tampak lebih kecil.

3.2.6 Hasil pada Sepuluh Wilayah

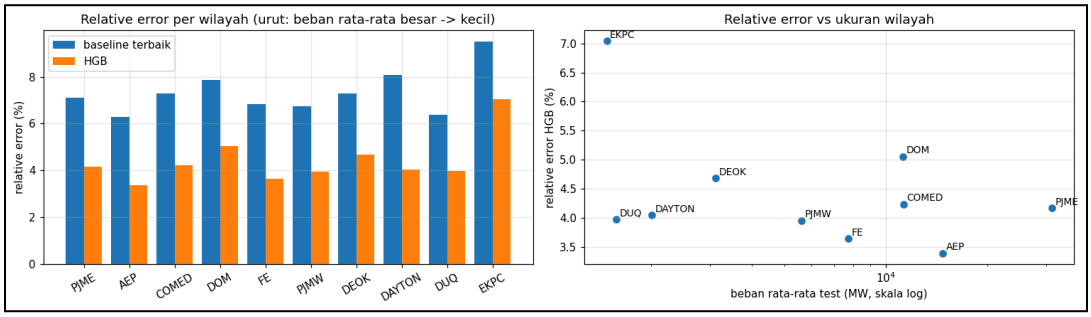
Pada sepuluh wilayah, dihasilkan data perbandingan HGB dengan periode *testing* 2016-01-01 sampai 2018-08-02 yang dirinci pada Tabel 8 berikut.

Tabel 8. Perbandingan Hasil HGB pada Sepuluh Wilayah (Periode *Testing* 2016-01-01 sampai 2018-08-02)

Wilayah	**Rata-rata beban (MW)**	**MAE (MW)**	***Relative error* HGB**	***Relative error baseline***	**R^2**	**MAE turun**	***Rolling* menang**
PJME	31.173	1.298	4,16%	7,11%	0,909	41,4%	8/8
AEP	14.783	500	3,38%	6,28%	0,922	46,1%	8/8
COMED	11.293	478	4,23%	7,31%	0,887	42,1%	8/8
DOM	11.238	568	5,05%	7,85%	0,892	35,7%	8/8
FE	7.741	282	3,64%	6,84%	0,904	46,8%	8/8
PJMW	5.609	221	3,95%	6,73%	0,902	41,4%	8/8
DEOK	3.117	146	4,68%	7,28%	0,880	35,7%	8/8
DAYTON	2.016	82	4,04%	8,07%	0,906	49,9%	8/8

Wilayah	Rata-rata beban (MW)	MAE (MW)	*Relative error* HGB	*Relative error baseline*	R^2	MAE turun	*Rolling* menang
DUQ	1.577	63	3,97%	6,38%	0,904	37,7%	8/8
EKPC	1.477	104	7,05%	9,51%	0,843	25,9%	8/8

Sementara itu, analisis *relative error* didasarkan pada plot grafik yang ditunjukkan pada Gambar 6 sebagai berikut.



(a) (b)

Gambar 6. *Relative Error* Baseline Terbaik dan HGB pada Tiap Wilayah (a) serta Hubungan *Relative Error* HGB dengan Beban Rata-Rata Wilayah dalam Skala Logaritmik (b)

Pada Tabel 8, HGB mengalahkan *baseline* terbaik di 10 dari 10 wilayah, dengan penurunan MAE antara 25,9% dan 49,9%. Pada evaluasi *rolling-origin*, HGB menang pada 80 dari 80 *fold* gabungan seluruh wilayah. *Relative error* HGB terendah terdapat pada AEP (3,38%) dan tertinggi pada EKPC (7,05%). Selain itu, pada Gambar 6a, batang HGB lebih rendah daripada batang *baseline* di setiap wilayah. Nilai EKPC paling tinggi untuk kedua batang (*baseline* 9,51%), yang menunjukkan bahwa deret beban EKPC memang lebih sulit diprediksi dan bukan hanya model yang kurang cocok. EKPC memiliki beban rata-rata terkecil dan data *training* terpendek (sekitar 2,6 tahun), tetapi kedua kemungkinan penyebab ini belum diuji.

Pada Gambar 6b, tidak tampak hubungan yang jelas antara ukuran wilayah dan *relative error*. Korelasi antara logaritma beban rata-rata dan *relative error* HGB adalah r = -0,42, tetapi hanya didasarkan pada 10 titik sehingga hanya bersifat indikatif. DUQ dan DAYTON memiliki beban rata-rata yang kecil seperti EKPC, tetapi *relative error*-nya sekitar 4%. Uji *perturbation* tidak menemukan *feature* yang berubah pada seluruh wilayah sehingga tidak ada indikasi *data leakage*. Hasil ini menunjukkan bahwa pola yang ditemukan pada PJME tidak khas untuk satu wilayah, tetapi berlaku pada sembilan wilayah lain dengan pipeline yang sama.

3.2.7 Hasil *Clustering*

Hasil *clustering* disajikan dalam dua tahap. Tahap pertama adalah hasil tuning *preprocessing* dan perbandingan algoritma. Tahap kedua adalah hasil konfigurasi yang akhirnya dipilih. Seluruh tahapan dijabarkan sebagai berikut.

1. Perbandingan algoritma

   Konfigurasi terbaik tiap algoritma pada PJME, dari 138 konfigurasi yang memenuhi syarat stabilitas dan ukuran cluster (dari 265 konfigurasi) disajikan pada Tabel 9 sebagai berikut.

   Tabel 9. Konfigurasi Terbaik Tiap Algoritma pada PJME, dari 138 Konfigurasi yang Memenuhi Syarat Stabilitas dan Ukuran *Cluster* (dari 265 Konfigurasi)

Algoritma	***Preprocessing***	**k**	***Score***	**Silhouette (ruang sendiri)**	**Stabilitas**	**R^2 rekonstruksi**
Spectral clustering	Standardisasi per jam (awal)	2	0,282	0,472	0,84	0,57
K-Means	Bentuk + level	2	0,279	0,336	0,98	0,55
GMM (*diagonal*)	Bentuk + level	2	0,273	0,277	0,96	0,27
GMM (*full*)	PCA 3 komponen	2	0,242	0,348	0,95	0,44
Agglomerative (Ward)	Bentuk saja (rasio ke rata-rata)	2	0,232	0,405	0,81	0,28

Pada Tabel 9, *spectral clustering* memperoleh *score* tertinggi (0,282), diikuti K-Means pada bentuk + level (0,279) dan *GMM* diagonal (0,273). Selisih tiga kandidat teratas hanya 0,010, sedangkan *GMM full* (0,242) dan Ward (0,232) lebih rendah. Semua algoritma memperoleh *score* tertinggi pada k = 2, dan *score* turun ketika k bertambah. Ward hanya memenuhi syarat stabilitas pada k = 2. *Agglomerative* dengan *linkage average* tidak punya konfigurasi yang memenuhi syarat: *score* tertinggi di seluruh grid (0,456) berasal dari konfigurasi ini, tetapi *cluster* terkecilnya hanya berisi sekitar 3 hari dan stabilitasnya 0,15. Artinya algoritma ini hanya memisahkan beberapa hari ekstrem dari sisanya, yang tidak berguna sebagai segmentasi. Secara keseluruhan 127 dari 265 konfigurasi gugur karena syarat tersebut.

2. Pengaruh *preprocessing*

Konfigurasi terbaik untuk tiap *preprocessing* pada PJME (yang memenuhi syarat) disajikan pada Tabel 10 sebagai berikut.

Tabel 10. Konfigurasi Terbaik untuk Tiap *Preprocessing* pada PJME (yang Memenuhi Syarat)

Preprocessing	**Algoritma terbaik**	**k**	***Score***	**Silhouette (ruang sendiri)**	**Stabilitas**	**R^2 rekonstruksi**
Standardisasi per jam (awal)	*Spectral clustering*	2	0,282	0,472	0,84	0,57
Bentuk + level	K-Means	2	0,279	0,336	0,98	0,55
MW asli (tanpa standardisasi)	K-Means	2	0,276	0,494	0,99	0,57
Min-max per jam	K-Means	2	0,273	0,480	0,99	0,57
Robust scaling per jam	K-Means	2	0,273	0,480	0,99	0,57
Bentuk saja (z-score per hari)	*GMM* (*diagonal*)	2	0,271	0,307	0,94	0,25
PCA 3 komponen	K-Means	2	0,271	0,489	0,98	0,56
PCA 95% variansi	K-Means	2	0,271	0,489	0,98	0,56
Log, lalu standardisasi	K-Means	2	0,260	0,459	0,97	0,55
Bentuk saja (rasio ke rata-rata)	K-Means	2	0,253	0,421	0,99	0,25

Tabel 10 menunjukkan bahwa *preprocessing* hampir tidak mengubah hasil K-Means. Pada k = 2, tujuh varian yang mempertahankan level beban (MW asli, standardisasi, *robust*, *min-max*, log, dan dua varian PCA) menghasilkan *score* 0,260–0,276 dan R^2 rekonstruksi 0,55–0,57. Simpangan baku beban per jam berkisar 3.665–6.984 MW sehingga standardisasi memang mengubah bobot tiap jam, tetapi pembagian harian hampir tidak berubah. Dugaan kami, variasi dominan antarhari (hari tinggi atau rendah) bergerak searah pada semua jam sehingga bobot per jam tidak banyak mengubah urutan kedekatan antarhari; dugaan ini tidak diuji lebih lanjut. Varian bentuk saja berbeda: R^2

rekonstruksinya hanya 0,10 (z-score per hari) dan 0,25 (rasio) karena level beban dibuang, sehingga rata-rata *cluster* tidak lagi mewakili profil dalam MW. Hasil *cluster*-nya berbeda secara kualitatif: pengelompokan menurut bentuk lebih berkaitan dengan bulan (NMI terhadap bulan 0,25 dibanding 0,13 pada MW asli), tetapi tidak memisahkan hari berdasarkan tinggi beban. Varian bentuk + level mengembalikan R^2 ke 0,55.

3. Uji perbedaan antar-kandidat

Perbedaan antarkandidat pada 10 *subsample* 70% (k = 2), serta selisih *score* terhadap K-Means standar (konfigurasi awal) pada *subsample* yang sama disajikan pada Tabel 11 sebagai berikut.

Tabel 11. *Score* Kandidat pada 10 *Subsample* 70% (k = 2) dan Selisihnya terhadap K-Means Standar (Konfigurasi Awal) pada *Subsample* yang Sama

Konfigurasi	**Rata-rata *score***	**Selisih terhadap awal (± SD)**	**Lebih baik pada (dari 10)**
K-Means, Standardisasi per jam (awal)	0,271	(acuan)	-
Spectral clustering, Standardisasi per jam (awal)	0,279	+0,007 ± 0,003	10
K-Means, Bentuk + level	0,279	+0,007 ± 0,002	10
GMM (*diagonal*), Bentuk saja (z-score per hari)	0,271	+0,000 ± 0,003	5
Agglomerative (Ward), Standardisasi per jam (awal)	0,272	+0,000 ± 0,013	8
GMM (*diagonal*), Standardisasi per jam (awal)	0,256	−0,015 ± 0,002	0
K-Means, MW asli (tanpa standardisasi)	0,276	+0,005 ± 0,001	10

Pada Tabel 11, *spectral clustering* (+0,007), bentuk + level (+0,007), dan K-Means MW asli (+0,005) mengungguli K-Means standar pada 10, 10, dan 10 dari 10 *subsample*. Konsisten, tetapi selisihnya hanya sekitar 0,005–0,007 pada skala Silhouette yang berkisar antara −1 dan 1, sehingga secara praktis tidak mengubah pembagian hari. Ward tidak berbeda dari K-Means standar (+0,000 ± 0,013, simpangan besar), sedangkan *GMM* diagonal pada data standar lebih rendah (−0,015, tidak pernah lebih baik).

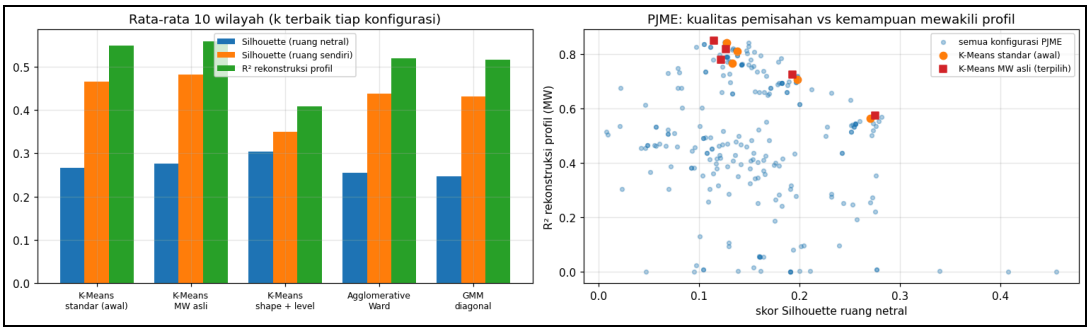
4. Konsistensi pada sepuluh wilayah

Konsistensi wilayah dianalisis dengan data rata-rata 10 wilayah untuk lima konfigurasi disajikan pada Tabel 12 berikut.

Tabel 12. Rata-rata 10 Wilayah untuk Lima Konfigurasi (k Terbaik di Tiap Wilayah di antara yang Memenuhi Syarat)

Konfigurasi	***Score***	**Silhouette (ruang sendiri)**	**Davies-Bouldin**	**Stabilitas**	**R^2 rekonstruksi**
K-Means, Standardisasi per jam (awal)	0,267	0,465	0,850	0,97	0,55
K-Means, MW asli (tanpa standardisasi)	0,277	0,482	0,817	0,97	0,56
K-Means, Bentuk + level	0,304	0,350	1,191	0,96	0,41
Agglomerative (Ward), Standardisasi per jam (awal)	0,254	0,438	0,862	0,52	0,52
GMM (*diagonal*), Standardisasi per jam (awal)	0,246	0,432	0,870	0,97	0,52

Pada Tabel 12, bentuk + level memiliki *score* tertinggi (0,304), tetapi R^2 rekonstruksi paling rendah (0,41 dibanding 0,55 pada konfigurasi awal). *Score*-nya juga cenderung menguntungkan konfigurasi ini karena salah satu ruang pembanding (S2) adalah ruang bentuk, yaitu ruang yang dipakai konfigurasi tersebut. K-Means MW asli lebih tinggi daripada K-Means standar (0,277 vs 0,267), dan R^2 rekonstruksinya juga lebih tinggi (0,56 vs 0,55). Pada k = 2 per wilayah, MW asli unggul dalam *score* di 7 dari 10 wilayah dan dalam R^2 rekonstruksi di 10 dari 10 wilayah. Ward (0,254) dan *GMM* diagonal (0,246) lebih rendah, dan Ward tidak stabil (stabilitas rata-rata 0,52). Sementara itu, perbandingan lima konfigurasi pada rata-rata sepuluh wilayah dan hubungan antara *score* Silhouette di ruang netral dan R^2 rekonstruksi pada seluruh konfigurasi PJME disajikan pada Gambar 7 sebagai berikut.



(a) (b)

Gambar 7. Perbandingan Lima Konfigurasi pada Rata-rata Sepuluh Wilayah (a) dan Hubungan antara *Score* Silhouette di Ruang Netral dan R^2 Rekonstruksi pada Seluruh Konfigurasi PJME (b)

Pada Gambar 7a, K-Means MW asli lebih tinggi daripada K-Means standar pada ketiga ukuran, sedangkan bentuk + level unggul pada *score*, tetapi turun jauh pada Silhouette ruang sendiri dan R^2 rekonstruksi. Pada Gambar 7b, dari 24 konfigurasi dengan *score* $\geq$ 0,25 dan $R^2 \geq$ 0,5, sebanyak 23 pada k = 2, dan semuanya menumpuk pada *score* 0,25–0,28; tidak ada konfigurasi yang jauh lebih baik pada kedua sumbu sekaligus. Untuk k yang lebih besar, R^2 rekonstruksi naik (karena lebih banyak *cluster* berarti rata-rata yang lebih rinci) tetapi *score* turun. Titik-titik di dasar grafik dengan R^2 mendekati nol adalah konfigurasi yang memisahkan segelintir hari saja (termasuk *agglomerative average* di atas), sehingga tidak berguna meskipun *score*-nya tinggi.

5. Konfigurasi yang dipilih

Aturan seleksi yang ditetapkan sebelumnya akan memilih *spectral clustering* pada data standar (k = 2, *score* 0,282). Konfigurasi ini tidak dipilih. Alasannya: selisihnya terhadap K-Means hanya +0,007, stabilitasnya paling rendah di antara kandidat teratas (0,84 dibanding 0,99 pada K-Means MW asli), dan implementasi *spectral clustering* di scikit-learn tidak menyediakan fungsi *predict* untuk hari baru. Bentuk + level tidak dipilih karena R^2 rekonstruksinya jauh lebih rendah pada rata-rata sepuluh wilayah. Konfigurasi yang dipilih adalah K-Means pada profil dalam MW tanpa standardisasi (PJME: *score* 0,276, stabilitas 0,99, R^2 rekonstruksi 0,57), dengan alasan: *score* dan R^2 rekonstruksi lebih baik daripada konfigurasi awal secara konsisten, stabilitasnya tinggi (setara varian K-Means lain, 0,97–0,99), dapat dipakai pada hari baru, dan lebih sederhana. Ini adalah keputusan pertimbangan yang diambil setelah melihat hasil, bukan keluaran otomatis dari aturan seleksi, sehingga perlu dicatat sebagai keputusan tim.

Hasil *tuning* menunjukkan tidak ada model yang jelas lebih baik daripada konfigurasi awal. Perubahan yang dipilih berupa perbaikan kecil yang konsisten, bukan lompatan kualitas. Kedua partisi juga mirip (ARI 0,82 pada k = 2 di PJME).

Sementara itu, Silhouette Score dan Davies-Bouldin Index untuk setiap nilai k pada konfigurasi terpilih (K-Means, MW asli) ditunjukkan pada Tabel 13 berikut.

Tabel 13. Silhouette Score dan Davies-Bouldin Index untuk Setiap Nilai k pada Konfigurasi Terpilih (K-Means, MW Asli), Dibandingkan dengan Konfigurasi Awal (K-Means, Standardisasi Per Jam)

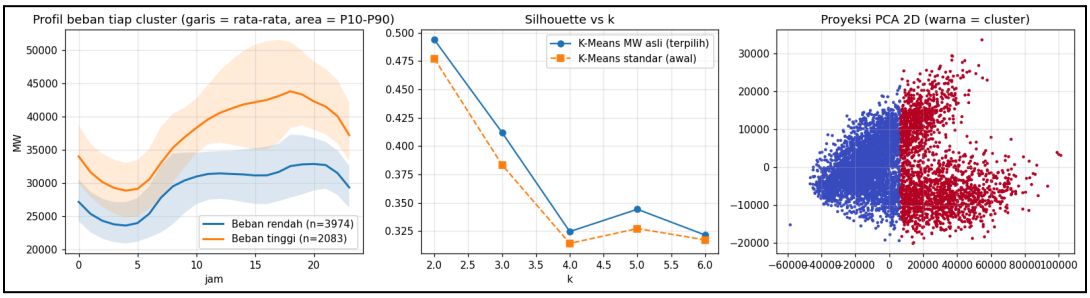
k	Silhouette (MW asli)	Silhouette (standar, awal)	Davies-Bouldin (MW asli)	*Cluster* terkecil (hari)	ARI antar-partisi
2	0,494	0,477	0,780	2.083	0,82
3	0,412	0,383	0,849	904	0,78
4	0,325	0,314	1,001	701	0,71
5	0,344	0,327	0,949	483	0,77
6	0,322	0,317	0,968	444	0,75

Pada Tabel 13, Silhouette Score konfigurasi terpilih tertinggi pada k = 2 (0,494) dan menurun pada k yang lebih besar (0,412 pada k = 3 dan 0,325 pada k = 4). Davies-Bouldin Index, yang bernilai lebih baik jika lebih kecil, juga terendah pada k = 2 (0,780). Kedua ukuran sama-sama memilih k = 2. Silhouette konfigurasi terpilih lebih tinggi daripada konfigurasi awal pada semua k, tetapi keduanya dihitung di ruang fitur masing-masing, sehingga selisih ini tidak dapat dibaca sebagai peningkatan kualitas sebesar itu; pembanding yang adil adalah *score* di ruang netral. Nilai Silhouette 0,494 juga masih jauh dari 1 sehingga pemisahan antar-*cluster* tidak tegas.

Selain itu, karakteristik *cluster* hasil K-Means MW asli ditunjukkan Tabel 14 dengan grafik pada Gambar 8 berikut.

Tabel 14. Karakteristik *Cluster* Hasil K-Means MW Asli (k = 2).

Cluster	Jumlah hari	Rata-rata beban (MW)	Hari akhir pekan	Jam puncak (median)
Beban rendah	3.974	29.316	34,8%	19:00
Beban tinggi	2.083	37.350	16,7%	17:00



(a) (b) (c)

Gambar 8. Profil Beban Rata-rata Tiap *Cluster* dengan Area P10–P90 (a), Silhouette Score untuk Setiap k pada Konfigurasi Terpilih dan Konfigurasi Awal (b), dan Proyeksi PCA 2 Dimensi (c)

Pada Tabel 14, *cluster* beban rendah berisi 3.974 hari dengan rata-rata 29.316 MW, dan 34,8% di antaranya jatuh pada akhir pekan. *Cluster* beban tinggi berisi 2.083 hari dengan rata-rata 37.350 MW, dan hanya 16,7% di antaranya jatuh pada akhir pekan. Jam puncak median *cluster* beban tinggi adalah pukul 17:00, lebih awal dibanding *cluster* beban rendah (pukul 19:00). Pada Gambar 8a, profil *cluster* beban tinggi berada di atas profil *cluster* beban rendah sepanjang hari dan mencapai sekitar 43.800 MW pada pukul 18:00. Area P10–P90 *cluster* beban tinggi juga lebih lebar (rata-rata sekitar 10.500 MW dibanding 7.700 MW), yang berarti variasi beban antarhari di dalam *cluster* ini lebih besar.

Dari sebaran bulan, 85,9% hari pada *cluster* beban tinggi berada pada Desember–Februari dan Juni–Agustus, sedangkan 68,7% hari pada *cluster* beban rendah berada pada Maret–Mei dan September–November. Dengan demikian, *cluster* beban tinggi dapat diartikan sebagai hari-hari ekstrem musim panas dan musim dingin, sedangkan *cluster* beban rendah berisi musim peralihan dan akhir pekan. Pada Gambar 8b, penurunan Silhouette Score dari k = 2 ke k = 4 mengonfirmasi bahwa pembagian yang lebih halus tidak menghasilkan kelompok yang lebih jelas. Pada Gambar 8c, titik-titik pada proyeksi PCA membentuk satu sebaran yang kontinu dan kedua *cluster* hanya terbelah di sekitar satu nilai pada sumbu PC1 tanpa celah di antaranya. Artinya, K-Means membagi satu kontinum hari menjadi dua bagian dan tidak menemukan dua kelompok yang terpisah secara alami.

3.3 *EVALUATION*

3.3.1 Evaluasi *Regression*

Evaluasi *regression* menggunakan empat ukuran berikut, dengan y adalah beban aktual, $\hat{y}$ adalah beban prediksi, $\bar{y}$ adalah rata-rata beban aktual, dan n adalah jumlah data. Formula tersebut dijabarkan sebagai berikut.

$$MAE = (1/n)\ \Sigma\ |y - \hat{y}|$$

$$RMSE = \sqrt{[\ (1/n)\ \Sigma\ (y - \hat{y})^2\ ]}$$

$$R^2 = 1 - \Sigma\ (y - \hat{y})^2\ /\ \Sigma\ (y - \bar{y})^2$$

$$Relative\ error = MAE\ /\ \bar{y} \times 100\%$$

MAE adalah rata-rata selisih absolut antara prediksi dan beban aktual dalam satuan MW. RMSE memberi bobot lebih besar pada *error* yang besar sehingga lebih sensitif terhadap kegagalan prediksi saat beban puncak. R^2 menunjukkan proporsi variasi beban yang dijelaskan model. *Relative error* menyatakan MAE sebagai persentase beban rata-rata sehingga dapat dibandingkan antarwilayah. MAPE (rata-rata dari $|y - \hat{y}| / y$) digunakan hanya pada analisis *error* menurut jam, bulan, dan jenis hari. Untuk *clustering* digunakan Silhouette Score, yaitu s = (b −

a) / max(a, b) dengan a jarak rata-rata ke anggota *cluster* sendiri dan b jarak rata-rata ke *cluster* terdekat lainnya, serta Davies-Bouldin Index yang makin baik jika makin kecil. Sementara itu, ringkasan evaluasi HGB ditunjukkan pada Tabel 15 berikut.

Tabel 15. Ringkasan Evaluasi HGB Dibandingkan *Baseline* Terbaik pada PJME

Ukuran	***Baseline* terbaik (lag24)**	**HGB**
MAE (MW)	2.209	1.275
RMSE (MW)	3.025	1.869
R^2	0,780	0,916
Relative error (rata-rata beban 31.323 MW)	7,05%	4,07%

Berdasarkan Tabel 15, HGB menurunkan MAE sebesar 42,3% dan RMSE sebesar 38,2% dibanding *baseline* lag24. Penurunan ini merupakan ukuran kemampuan prediksi yang paling berarti. Nilai R^2 0,916 terlihat tinggi, tetapi *baseline* lag24 saja sudah memperoleh R^2 0,780 karena siklus harian beban mudah ditebak. Dengan demikian, R^2 tidak dapat dipakai sendirian untuk menilai keunggulan model. Hasil ini juga konsisten antarwaktu (HGB lebih baik pada 8 dari 8 *fold rolling-origin*) dan antarwilayah (10 dari 10 wilayah). Untuk *clustering*, Silhouette Score 0,494 dan analisis PCA menunjukkan bahwa pemisahan *cluster* tidak tegas, sehingga *cluster* berguna sebagai ringkasan deskriptif, bukan sebagai kelompok alami. Selain itu, terdapat catatan terhadap validitas hasil untuk diperhatikan sebagai berikut.

1. Set *feature snapshot* D-1 dirancang setelah percobaan awal yang juga melihat data *testing* PJME. Oleh karena itu, angka *testing* PJME kemungkinan sedikit lebih optimistis. Ukuran yang lebih aman adalah rata-rata *rolling-origin* (4,00%) dan urutan peningkatan yang sama pada *cross-validation* di dalam data *training*.
2. Setiap wilayah hanya diuji pada satu periode sekitar 2,6 tahun tanpa data cuaca. Signifikansi statistik antarwilayah tidak diuji, dan wilayah yang berdekatan berbagi kondisi cuaca sehingga hasilnya tidak sepenuhnya independen.
3. Set *feature* dan rentang *hyperparameter* dirancang pada PJME dan dipakai apa adanya pada wilayah lain.
4. Nilai yang tidak masuk akal dibuang berdasarkan aturan, tidak berdasarkan verifikasi ke sumber asli.
5. Angka PJME memiliki dua protokol testing, yaitu 4,07% pada *testing* mulai 2015 dan 4,16% pada testing mulai 2016 untuk perbandingan antarwilayah**.**

3.3.2 Evaluasi *Clustering*

Data tidak memiliki label jenis hari yang sebenarnya, sehingga *clustering* dievaluasi dengan ukuran internal. Silhouette Score s = (b − a) / max(a, b), dengan a adalah jarak rata-rata suatu hari ke hari lain dalam *cluster* yang sama dan b adalah jarak rata-rata ke *cluster* terdekat lainnya; nilai 1 berarti terpisah sempurna dan nilai mendekati 0 berarti *cluster* saling tumpang tindih. Davies-Bouldin Index menilai rasio sebaran dalam *cluster* terhadap jarak antar-*cluster* (lebih kecil lebih baik). Stabilitas diukur dengan *Adjusted Rand Index* (ARI) antar-dua-hasil

clustering pada *subsample* berbeda (1 berarti pembagian identik). R^2 rekonstruksi = 1 − SSE / SST, yaitu proporsi variasi profil MW yang dijelaskan oleh rata-rata *cluster*.

Pada konfigurasi terpilih, Silhouette Score 0,494 (k = 2) menunjukkan pemisahan yang tidak tegas, stabilitas 0,99 menunjukkan bahwa pembagian hampir sama pada *subsample* berbeda, dan R^2 rekonstruksi 0,57 berarti rata-rata dua *cluster* menjelaskan sekitar 57% variasi profil harian. Bersama proyeksi PCA yang tidak menunjukkan celah antar-*cluster*, angka-angka ini mendukung pembacaan hasil sebagai ringkasan deskriptif, bukan kelompok alami. Sementara itu, terdapat beberapa catatan pada evaluasi *clustering* sebagai berikut.

1. Silhouette Score tidak dapat dibandingkan langsung antar-*preprocessing* karena dihitung di ruang fitur yang berbeda; perbandingan memakai *score* di dua ruang netral.
2. Konfigurasi akhir dipilih dengan pertimbangan setelah hasil dilihat, bukan keluaran otomatis dari aturan seleksi yang ditetapkan sebelumnya.
3. *Tuning* dan evaluasi memakai data yang sama karena analisis ini deskriptif dan tidak ada data *hold-out*, sehingga *score* konfigurasi pemenang cenderung sedikit optimistis. Uji berpasangan pada *subsample* dan pengulangan pada 9 wilayah mengurangi, tetapi tidak menghilangkan, risiko ini.
4. Jumlah *cluster* terbaik adalah k = 2 pada 9 dari 10 wilayah, sedangkan DOM memilih k = 3; *tuning* dilakukan paling lengkap pada PJME.

3.4 *ENGINEERING INTERPRETATION*

3.4.1 Interpretasi Hasil dari Perspektif Teknik Elektro

Model HGB memprediksi beban per jam satu hari ke depan dengan MAE 1.275 MW atau 4,07% dari beban rata-rata PJME. Bagi operator sistem, angka ini berarti bahwa pada kondisi *testing*, jadwal pembangkit yang disusun dari prediksi tersebut rata-rata hanya meleset sekitar 4,1% dari kebutuhan beban sebenarnya, jauh lebih kecil dibanding 7,1% jika hanya mengandalkan beban kemarin. Pada 90% jam, selisih prediksi dan beban aktual tidak melebihi sekitar 2.900 MW, dan pada 99% jam tidak melebihi sekitar 6.681 MW. Besaran ini dapat menjadi gambaran awal ketidakpastian yang perlu diantisipasi melalui cadangan daya. Biaya atau besar cadangan yang sebenarnya tidak dihitung karena data tarif dan kebijakan cadangan tidak tersedia.

Pola pada hasil juga sejalan dengan perilaku sistem tenaga. Beban naik pada jam kerja dan turun pada malam hari serta akhir pekan. *Error* terbesar muncul pada sore hari saat beban puncak, dan hari-hari dengan *error* terburuk didominasi akhir pekan. Pada *clustering*, hari-hari beban tinggi terkonsentrasi pada musim panas dan musim dingin, yang sesuai dengan dugaan bahwa beban pendingin dan pemanas ruangan membentuk beban puncak tahunan. Dugaan terkait suhu ini konsisten dengan data, tetapi tidak dapat dipastikan karena suhu tidak termasuk dalam *dataset*.

Informasi yang paling berharga bagi model adalah kondisi beban terbaru, yaitu beban pukul 23:00 hari sebelumnya dan beban pada jam yang sama kemarin. Secara praktis, hal ini berarti bahwa kualitas prediksi *day-ahead* sangat bergantung pada ketersediaan data pengukuran

beban yang cepat dan akurat dari sistem SCADA sampai saat prediksi dibuat. Selain itu, perbedaan akurasi antara HGB, Random Forest, dan Ridge yang kecil menunjukkan bahwa model sederhana yang mudah dijelaskan sudah cukup memberikan hasil yang mendekati model yang lebih kompleks pada data ini.

3.4.2 Manfaat Hasil Model AI

Model AI yang digunakan pada proyek ini memiliki potensi manfaat sebagai berikut.

1. Prediksi beban per jam untuk 24 jam ke depan yang lebih akurat dibanding *baseline* sederhana, sehingga dapat mendukung penyusunan jadwal pembangkit.
2. Gambaran besar ketidakpastian prediksi (P90 dan P99 *error*) sebagai dasar awal diskusi mengenai cadangan daya.
3. Pengelompokan hari menjadi profil beban rendah dan tinggi yang membantu perencana mengenali hari-hari yang perlu mendapat perhatian lebih.

3.4.3 Penggunaan dalam Sistem Teknik Elektro

Model dapat dijalankan setiap hari pada pukul 00:00 sebagai bagian dari perangkat bantu perencanaan operasi, misalnya untuk menyusun jadwal pembangkit (*unit commitment*) dan menentukan margin cadangan. Hasil *clustering* dapat dipakai untuk menandai hari yang diperkirakan masuk ke profil beban tinggi. Karena model dilatih terpisah untuk tiap wilayah dan pipeline-nya sama, pendekatan yang sama dapat diterapkan pada wilayah lain selama tersedia data beban per jam yang cukup panjang.

3.4.4 Keterbatasan

Pengembangan dan implementasi model AI pada proyek ini memiliki keterbatasan sebagai berikut.

1. Model tidak memakai data cuaca, padahal beban sangat dipengaruhi suhu. Prediksi pada hari dengan perubahan cuaca mendadak kemungkinan lebih buruk.
2. Data berasal dari satu jaringan di Amerika Serikat dengan iklim, kalender libur, dan kebiasaan konsumsi yang berbeda dari Indonesia (misalnya tidak ada musim dingin dan ada libur Lebaran). Hasil tidak dapat langsung diterapkan di Indonesia.
3. Setiap wilayah hanya diuji pada satu periode sekitar 2,6 tahun, dan beberapa keputusan perancangan dibuat pada PJME.
4. Model hanya memberikan satu nilai prediksi tanpa interval ketidakpastian, sedangkan *error* besar tetap dapat terjadi (maksimum 13.556 MW pada PJME).
5. Data tidak diverifikasi ke sumber asli PJM, dan beberapa nilai yang diragukan tetap dipertahankan.
6. Hasil *clustering* membagi satu kontinum hari menjadi dua bagian dan tidak ditemukan model *clustering* yang jelas lebih baik dari K-Means; perbaikan dari *tuning* bersifat kecil.

3.4.5 Pengembangan di Dunia Nyata

Model AI yang dikembangkan pada proyek ini memiliki potensi untuk dikembangkan dengan rincian sebagai berikut.

1. Menambahkan prakiraan suhu dan variabel cuaca lain sebagai *feature*.
2. Menghasilkan interval prediksi (*probabilistic forecasting*) agar penentuan cadangan daya dapat dikaitkan langsung dengan tingkat risiko.
3. Memvalidasi model dengan data beban Indonesia, dengan memasukkan kalender libur nasional dan hari besar keagamaan.
4. Menambahkan pemantauan akurasi secara berkelanjutan dan pelatihan ulang model secara berkala setelah model dipakai pada operasi nyata.
5. Menguji pada periode yang lebih panjang dan menguji signifikansi statistik antarwilayah.

BAB 4. KESIMPULAN

Berdasarkan hasil pengujian, model HistGradientBoosting dengan *feature* kalender dan riwayat beban yang bebas dari *data leakage* mampu memprediksi beban PJME per jam satu hari ke depan dengan MAE 1.275 MW (*relative error* 4,07%), RMSE 1.869 MW, dan R^2 0,916 pada periode 2015–2018. Nilai MAE tersebut 42,3% lebih rendah daripada *baseline* persistensi harian. Hasil ini konsisten pada 8 dari 8 *fold rolling-origin* dengan rata-rata *relative error* 4,00%, yang merupakan ukuran paling aman karena tidak bergantung pada satu periode *testing*.

Ablation study dan *permutation importance* menunjukkan bahwa peningkatan akurasi terutama berasal dari *feature* kondisi beban terbaru (beban pukul 23:00 hari sebelumnya dan beban pada jam yang sama kemarin), bukan dari kompleksitas algoritma, karena Random Forest dan Ridge menghasilkan R^2 yang berdekatan. Pipeline yang sama pada 10 wilayah menghasilkan *relative error* 3,38% sampai 7,05% dan HGB mengalahkan *baseline* terbaik di 10 dari 10 wilayah, sehingga hasil PJME tidak khas untuk satu wilayah.

Clustering K-Means pada profil dalam MW tanpa standardisasi dengan k = 2 (Silhouette Score 0,494) membagi hari menjadi *cluster* beban rendah dan beban tinggi yang berkaitan dengan musim dan akhir pekan. Tuning 265 konfigurasi (10 *preprocessing*, 6 algoritma, k = 2 sampai 6) tidak menemukan model yang jelas lebih baik: konfigurasi terpilih hanya sedikit lebih baik daripada konfigurasi awal secara konsisten, dan dipilih sebagai keputusan pertimbangan, bukan keluaran otomatis dari aturan seleksi (yang akan memilih *spectral clustering* dengan selisih +0,007). Karena data membentuk kontinum, *cluster* ini lebih tepat dipakai sebagai ringkasan deskriptif.

Keterbatasan utama adalah tidak adanya data cuaca, pengujian pada satu periode untuk tiap wilayah, dan data yang berasal dari Amerika Serikat. Pengembangan selanjutnya mencakup penambahan prakiraan suhu, prediksi probabilistik, dan validasi pada data beban Indonesia.

DAFTAR PUSTAKA

[1] Kementerian ESDM, “Paparkan Capaian 2023, Menteri ESDM Klaim Peningkatan Rasio Elektrifikasi,” 15 Jan. 2024. [Online]. Available: https://www.esdm.go.id/id/berita-unit/direktorat-jenderal-ketenagalistrikan/paparkan-capaian-2023-menteri-esdm-klaim-peningkatan-rasio-elektrifikasi (Diakses pada 6 Oktober 2026).

[2] Kementerian ESDM, “Tertinggal dari Negara Lain, Kementerian ESDM Libatkan Stakeholder dalam Diskusi Peningkatan Konsumsi Listrik Per Kapita,” 25 Nov. 2022. [Online]. Available: https://esdm.go.id/id/berita-unit/direktorat-jenderal-ketenagalistrikan/tertinggal-dari-negara-lain-kementerian-esdm-libatkan-stakeholder-dalam-diskusi-peningkatan-konsumsi-listrik-per-kapita (Diakses pada 6 Oktober 2026).

[3] hukumonline, “Bahlil Resmi Umumkan RUPTL Tahun 2025–2034,” 26 Mei 2025. [Online]. Available: https://www.hukumonline.com/berita/a/bahlil-resmi-umumkan-ruptl-tahun-2025-2034-lt68344d6f0dc8a (Diakses pada 8 Oktober 2026).

[4] Investortrust, “PLN Bersiap Hadapi Lonjakan Permintaan Listrik 511 TWh, dari ‘Data Center’ hingga EV,” 2 Jun. 2025. [Online]. Available: https://investortrust.id/business/68024/pln-bersiap-hadapi-lonjakan-permintaan-listrik-511-twh-dari-data-center-hingga-ev (Diakses pada 8 Oktober 2026).

[5] Kementerian ESDM, “Kunjungi APB Ungaran, Menteri ESDM Pastikan Listrik Jawa Bali Aman Jelang Libur Akhir Tahun,” 13 Des. 2018. [Online]. Available: https://esdm.go.id/id/berita-unit/direktorat-jenderal-ketenagalistrikan/kunjungi-apb-ungaran-menteri-esdm-pastikan-listrik-jawa-bali-aman-jelang-libur-akhir-tahun (Diakses pada 11 Oktober 2026).

[6] Bisnis.com, “ESDM Catat Kelebihan Pasokan Listrik Jawa-Bali Turun jadi 4 GW pada 2023,” 18 Jan. 2024. [Online]. Available: https://ekonomi.bisnis.com/read/20240118/44/1733610/esdm-catat-kelebihan-pasokan-listrik-jawa-bali-turun-jadi-4-gw-pada-2023 (Diakses pada 12 Oktober 2026).

[7] T. Hong, “Crystal ball lessons in predictive analytics,” *EnergyBiz*, pp. 35–37, Spring 2015. [Online]. Available: https://blog.drhongtao.com/2015/04/crystal-ball-lessons-in-predictive-analytics.html (Diakses pada 12 Oktober 2026).

[8] M. F. Ainuri, Sarjiya, and I. Ardiyanto, “Short-term load forecasting with long short-term memory: A case study of Java-Bali system,” in *Proc. 12th Int. Conf. Inf. Technol. Electr. Eng. (ICITEE)*, Yogyakarta, Indonesia, 2020, pp. 257–262, doi: 10.1109/ICITEE49829.2020.9271763.

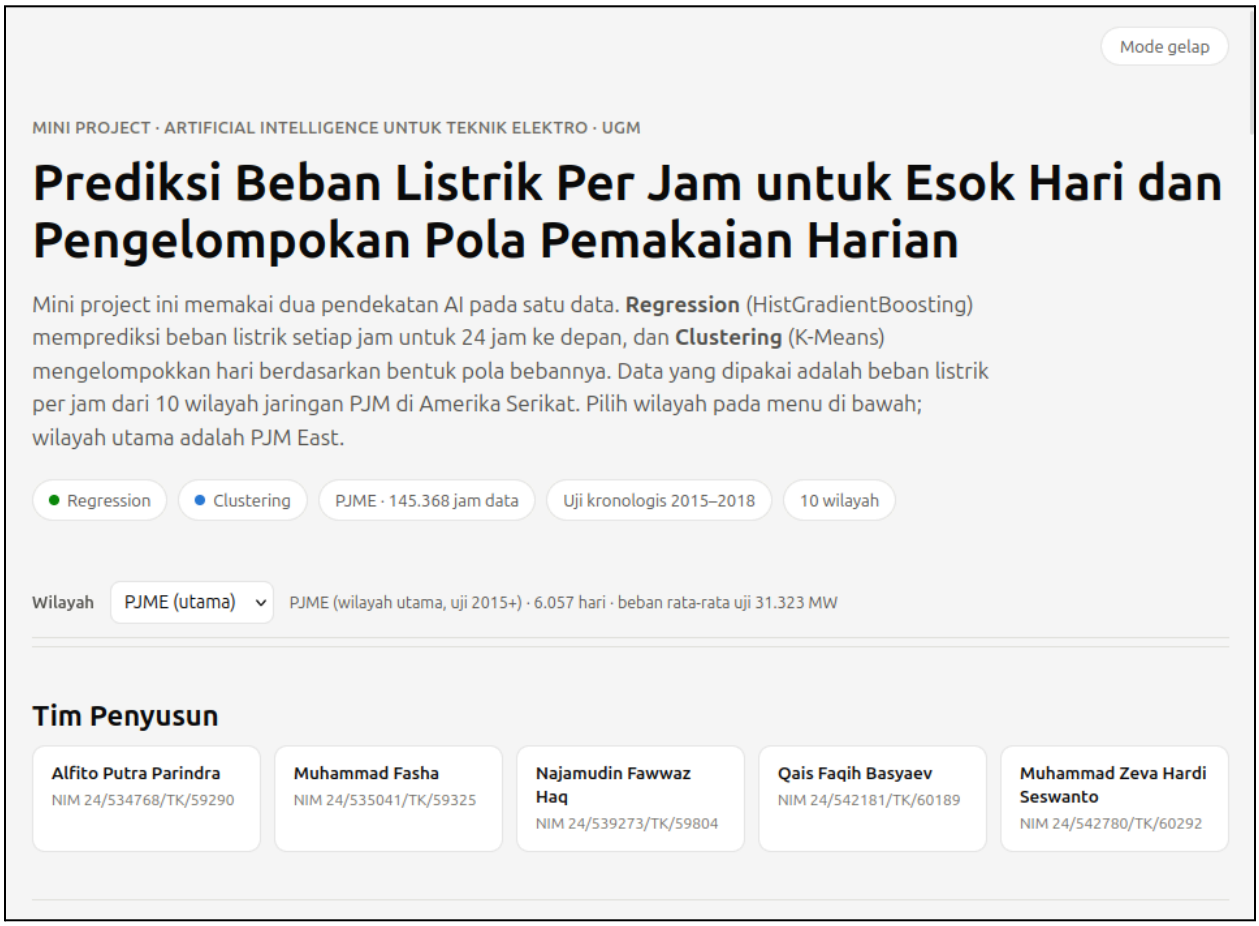
[9] robikscube, “Hourly Energy Consumption,” Kaggle. [Online]. Available: https://www.kaggle.com/datasets/robikscube/hourly-energy-consumption

[10] ashishkumarrana, “PJM Hourly Energy Consumption,” Kaggle. [Online]. Available: https://www.kaggle.com/datasets/ashishkumarrana/pjm-hourly-energy-consumption

[11] “PJM Hourly Energy Consumption,” IEEE DataPort. [Online]. Available: https://ieee-dataport.org/documents/pjm-hourly-energy-consumption
[12] navyasancheti, “PJME-Hourly-Energy-Consumption,” GitHub repository. [Online]. Available: https://github.com/navyasancheti/PJME-Hourly-Energy-Consumption
[13] panambY, “Hourly_Energy_Consumption,” GitHub repository. [Online]. Available: https://github.com/panambY/Hourly_Energy_Consumption
[14] PJM Interconnection, “PJM prepared to meet summer electricity demand,” *Inside Lines*, 11 Mei 2022. [Online]. Available: https://insidelines.pjm.com/?p=205370 (Diakses pada 12 Oktober 2026).
[15] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
[16] Python package *holidays*, modul *holidays.US* (kalender libur nasional Amerika Serikat), versi 0.106.

LAMPIRAN

LAMPIRAN 1. *DASHBOARD WEBSITE MINI-PROJECT* AI



Website dapat diakses pada Tautan: loads-ai.vercel.app

LAMPIRAN 2. TAUTAN GITHUB *REPOSITORY* DAN *FOLDER* GOOGLE DRIVE DARI *NOTEBOOK* MODEL AI YANG DIKEMBANGKAN

1. Tautan repositori Github: https://github.com/putraparindra/pjmloads-ai-14
2. Tautan *folder* Google Drive: https://s.id/gOqlo

LAMPIRAN 3. *GRID HYPERPARAMETER* HGB

Tabel 16. *Grid Hyperparameter* HGB dan Parameter Terbaik pada PJME.

Parameter	Nilai yang dicoba (PJME, analisis utama)	Nilai yang dicoba (analisis 10 wilayah)	Terbaik pada PJME (analisis utama)
learning_rate	0,03; 0,06	0,06 (tetap)	0,06
max_iter	400; 800	400; 800	800
max_leaf_nodes	31; 63	31; 63	31
min_samples_leaf	50; 100	50; 100	50

Pada Tabel 16, *grid* analisis utama PJME terdiri atas 16 kombinasi, sedangkan grid pada analisis sepuluh wilayah terdiri atas 8 kombinasi karena *learning_rate* dibuat tetap untuk menghemat waktu komputasi. Seluruh *tuning* memakai GridSearchCV dengan TimeSeriesSplit 4 *fold* dan skor MAE pada data *training*.

LAMPIRAN 4. HASIL *CLUSTERING* PADA SEPULUH WILAYAH

Tabel 17. Hasil *Clustering* K-Means MW Asli pada Setiap Wilayah, Dibandingkan dengan Konfigurasi Awal (Standardisasi Per Jam).

Wilayah	k terpilih	Silhouette (MW asli)	Silhouette (standar, awal)	ARI antar-partisi
PJME	2	0,494	0,477	0,82
AEP	2	0,441	0,447	0,95
COMED	2	0,533	0,485	0,72
DAYTON	2	0,450	0,446	0,87
DEOK	2	0,486	0,469	0,79
DOM	3	0,486	0,479	0,94
DUQ	2	0,494	0,467	0,76
EKPC	2	0,526	0,478	0,75
FE	2	0,467	0,452	0,81
PJMW	2	0,448	0,454	0,96

Pada Tabel 17, Silhouette konfigurasi terpilih lebih tinggi daripada konfigurasi awal pada 8 dari 10 wilayah, dan kedua partisi sangat mirip (ARI 0,72–0,96). Perlu diingat bahwa kedua Silhouette dihitung di ruang fitur masing-masing sehingga selisihnya tidak dapat dibaca sebagai peningkatan kualitas.